



تحلیل جامع بازار املاک در پلتفرم دیوار

نام موسسه: مدرسه پردازش و تحلیل داده دقیقه

تهیه کنندگان: کورش خدائی نمین / زینب السادات حسینی / ایلیا طاهری نیا

معرفی مجموعه داده

+۱M

آگهی املاک

بیش از یک میلیون آگهی معتبر از پلتفرم دیوار

۶۰

ویژگی

شصت ستون ویژگی شامل اطلاعات مالی، فیزیکی و مکانی

۱۶

دسته بندی

شانزده نوع ملک از آپارتمان تا ویلا و املاک تجاری

این مجموعه داده بازتابی زنده از رفتار اقتصادی، قیمت گذاری، ترجیحات کاربران و پویایی های بازار مسکن در ایران است.

ساختار داده‌ها

مشخصات فیزیکی و مالی

- ابعاد ملک (متراژ زمین و بنا)
- قیمت، اجاره، رهن و ودیعه
- جزئیات ساختمان (طبقه، اتاق، سال ساخت)

دسته‌بندی و موقعیت

- نوع معامله و ملک (اجاره، فروش، آپارتمان، ویلا)
- موقعیت جغرافیایی (شهر، محله، مختصات)
- اطلاعات آگهی دهنده و زمان ثبت



امکانات و ویژگی‌های املاک



امکانات لوکس

استخر، جکوزی، سونا و نگهبانی



انشعابات اصلی

آب، برق، گاز و سیستم‌های گرمایشی و سرمایشی



امکانات پایه

آسانسور، پارکینگ، انباری و بالکن

تحلیل اکتشافی: شناخت اولیه

در نخستین گام‌های اکتشافی، ساختار داده‌ها، مقادیر گمشده و نوع داده‌ها بررسی شد. داده‌ها مخلوطی از رشته‌های فارسی و انگلیسی، اعداد با فرمت‌های مختلف و کاراکترهای خاص بودند.

نقاط پرت

وجود مقادیر غیرواقعی شدید در متغیرهای
قیمت و ابعاد

مقادیر گمشده

درصد بالایی از ستون‌های مرتبط با
مشخصات کمی ملک دارای مقادیر خالی
بودند

استانداردسازی

نیاز به تبدیل فرمت نوشتاری و
یکپارچه‌سازی داده‌ها



دسته‌بندی ویژگی‌ها

۰۱

متغیرهای عددی پیوسته

۱۶ ستون شامل قیمت، اجاره، رهن، متراژ و مختصات جغرافیایی

۰۲

متغیرهای عددی گسسته

۷ ستون شامل تعداد اتاق، طبقات، سال ساخت و ظرفیت

۰۳

متغیرهای بولین

۱۷ ستون نشان‌دهنده وجود یا عدم وجود امکانات

۰۴

متغیرهای دسته‌بندی

۱۷ ستون شامل نوع ملک، محله، جهت ساختمان و جنس کف

۰۵

متغیرهای متنی

۳ ستون شامل عنوان، توضیحات و تاریخ ثبت آگهی

کشف روابط: همبستگی با اجاره

- همبستگی های قوی ترین

 - location_latitude: ۰.۷۲
 - price_value: ۰.۶۵
 - credit_value: ۰.۵۴
- همبستگی های متوسط

 - building_size: ۰.۵۰
 - rooms_count: ۰.۴۱
 - land_size: ۰.۳۳
- همبستگی های ضعیف

 - floor: ۰.۱۷
 - construction_year: ۰.۱۰
 - location_longitude: ۰.۰۲

hambastegi adadi (Spearman)									
0.65	0.54	0.33	0.50	0.17	0.41	0.26	0.13	0.10	0.72
1.00	0.60	0.65	0.65	0.19	0.55	0.32	0.07	0.15	0.56
0.60	1.00	0.29	0.52	0.21	0.45	0.25	0.14	0.22	0.60
0.65	0.29	1.00	0.65	0.19	0.50	0.22	0.00	0.23	0.30
0.65	0.52	0.65	1.00	0.24	0.76	0.27	-0.01	0.26	0.46
0.19	0.21	0.19	0.24	1.00	0.19	0.33	0.18	0.27	0.16
0.55	0.45	0.50	0.76	0.19	1.00	0.18	-0.05	0.19	0.38
0.32	0.25	0.22	0.27	0.33	0.18	1.00	0.52	0.32	0.25
0.07	0.14	0.00	-0.01	0.18	-0.05	0.52	1.00	0.12	0.17
0.15	0.22	0.23	0.26	0.27	0.19	0.32	0.12	1.00	0.13
0.56	0.60	0.30	0.46	0.16	0.38	0.25	0.17	0.13	1.00
0.09	-0.06	0.03	0.03	-0.06	0.02	-0.06	-0.16	-0.07	0.03
price_value	credit_value	land_size	building_size	floor	rooms_count	total_floors_count	unit_per_floor	construction_year	location_latitude



کشف روابط: همبستگی با قیمت

همبستگی خوب

- location_latitude: ۰.۵۶
- rooms_count: ۰.۵۵

قوی ترین همبستگی ها

- rent_value: ۰.۶۵
- land_size: ۰.۶۵
- building_size: ۰.۶۵
- credit_value: ۰.۶۰

پاکسازی داده‌ها: مدیریت تکرار

در بررسی داده‌های تکراری، چالش اصلی تشخیص املاک واقعاً یکسان از آگهی‌های مجدد بود. استراتژی تفکیک داده‌ها به دو دسته اتخاذ شد:

۳

حذف داده‌های تکراری

۸,۷۹۰ رکورد تکراری از میان ۹۸۱,۶۷۵ رکورد

شناسایی و حذف شد

۲

شناسایی تکراری

اجرای الگوریتم فقط روی داده‌های باکیفیت

۱

داده‌های باکیفیت

رکوردهایی با مقادیر کامل در ستون‌های کلیدی مانند

متراژ و قیمت



استانداردسازی و یکپارچه سازی



مقادیر بولین

یکپارچه سازی تمام خانه ها با مقادیر True یا False



دسته بندی

تبدیل ستون های دسته بندی به نوع categorical
با مقدار missing برای NaN ها



تبدیل اعداد

پاکسازی و تبدیل اعداد فارسی، حروف و علائم
غیر عددی به فرمت استاندارد

خوشه بندی CLUSTERING: هدف و روش

هدف اصلی، گروه‌بندی املاک بر اساس ویژگی‌های عددی و نوعی به گونه‌ای که بیشترین شباهت ساختاری و رفتاری را داشته باشند.

پیش‌پردازش

مدیریت مقادیر خالی، حذف پرت‌ها و استانداردسازی

۱

۲

K-Means

اجرای الگوریتم و یافتن تعداد بهینه خوشه‌ها

۳

کاهش ابعاد

استفاده از PCA برای ارزیابی پایداری

۴

تحلیل نهایی

بررسی فضاها ۱۱ و ۸ بعدی

مدیریت مقادیر گمشده

مقادیر گمشده براساس نوع معامله (cat₂_slug) بررسی شد. خالی بودن مقادیر فروش در معاملات اجاره بدیهی و اجتناب‌ناپذیر است.



جایگزینی داده صحیح

جایگزینی مقادیر گم‌شده
براساس تحلیل آماری



حذف ستون‌های ضعیف

حذف ویژگی‌های
کم‌ارزش

مدیریت مقادیر پرت

۱

شناسایی مقادیر غیرواقعی

قیمت‌های ۹۹۹ تریلیون تومان و مترážهای ۱۰ میلیون متر مربع

۲

حذف رکوردهای پرت

حذف آگهی‌های با داده‌های کاملاً غیرمنطقی

۳

تبدیل لگاریتمی

اعمال تبدیل log برای کاهش چولگی توزیع

۴

استفاده از چارک‌ها

محاسبه آستانه براساس IQR و توزیع واقعی داده‌ها

۵

تفکیک براساس نوع

اجرای مجدد براساس نوع ملک برای دقت بیشتر

پیدا کردن بهترین تعداد خوشه‌ها

محاسبه WCSS


۱

رسم نمودار Elbow

۲

شناسایی نقطه بهینه $K=8$

۳



نتایج خوشه بندی




واریانس حفظ شده

واریانس حفظ شده با ۸ مولفه اصلی در PCA




پایداری خوشه

حداقل پایداری خوشه در فضاهای مختلف



Real Estate Price Category Distribution



مدلسازی قیمت: آماده سازی

پیش از مدل سازی، یک مرحله پاکسازی جامع انجام شد تا داده ها به شکلی پایدار و قابل تحلیل آماده شوند.

تکمیل ویژگی ها

پر کردن مقادیر گم شده و تزریق اطلاعات

اصلاح ابعاد

همسان سازی و مقیاس بندی ویژگی ها

پاکسازی قیمت ها

حذف داده های نادرست و پراکندگی

مهندسی ویژگی



سن بنا

محاسبه سن ملک با کسر سال ساخت از ۱۴۰۳ برای مدل سازی فرسودگی




اثر طبقه و آسانسور

ویژگی ترکیبی با وزن ۱.۵ برای آسانسور و ۰.۷ بدون آسانسور



میانگین قیمت محله

محاسبه میانه قیمت در هر محله برای لحاظ کردن تأثیر منطقه



مقایسه مدل‌های رگرسیون: مراحل و نتایج

مرحله اول: مدل‌های پایه (بدون تنظیم)

KNN Regressor	۰.۸۳	بهترین عملکرد در تنظیم اولیه با وزن distance
Linear Regression	۰.۷۷	عملکرد قابل قبول با سادگی بالا
Decision Tree	۰.۷۶	نزدیک به رگرسیون خطی، نیاز به تنظیم
MLP (پایه)	منفی	عملکرد بسیار ضعیف، بدتر از میانگین

اثر تاثیر فرایارامترها در MLP

بهترین تنظیمات:

- معماری: یک لایه پنهان با ۶۴ نورون
- فعال سازی: ReLU
- حداکثر تکرار: حدود ۲۰۰

نتیجه: R^2 همچنان منفی (عملکرد ضعیف)

دلایل ضعف MLP

تعداد زیاد ویژگی های تنک (OneHot)

معماری ساده نسبت به پیچیدگی الگوها

هم خطی و هم پوشانی زیاد ویژگی ها



حتی با تغییرات متوالی در معماری، MLP نتوانست به دقت KNN یا Decision Tree نزدیک شود



دسته‌بندی قیمتی املاک

گران ($1.2 <$)
مناسب ($1.2 - 0.8$)
ارزان ($0.8 >$)
بسیار ارزان



۱.۸K

ارزان

۲K

گران


۹K

قیمت مناسب

تحلیل مکانی دسته‌های قیمتی

بررسی توزیع جغرافیایی نشان داد که محله‌هایی مانند پونک، جیحون و سازمان برنامه بیشترین تعداد آگهی با قیمت مناسب را دارند.

tedad khane dar 4 mahale por tekrarnormal



قیمت مناسب

تعادل نسبی عرضه و تقاضا در مناطق مانند پونک و جیحون

املاک گران

تمرکز در پونک، چیتگر-لیک و سرسبیل با قیمت ۲۰-۳۰٪ بالاتر

فرصت‌های خرید

املاک ارزان با قیمت نصف سطح مناسب، مناسب برای سرمایه‌گذاری

بارگذاری داده و بررسی اولیه برای دسته بندی متنی


عملیات بر روی خروجی مرحله قبل که حاوی متون پاکسازی، ریشه یابی و توکن سازی شده در ستون `clean_text` بود انجام شد.



نمونه برداری تصادفی برای مدل سازی



رکورد غیرتهی در user_type



کلاس مختلف در cat3_slug



رکورد کل

استخراج ویژگی متنی و برداری سازی

رویکرد یادگیری عمیق

- Tokenizer

مدل مبتنی بر تعبیه (Embedding)

- Word2Vec

مدل های مبتنی بر شمارش

- Bag of Words
- TF-IDF

مدل سازی دسته بندی cat₃_slug

برای مقایسه عملکرد رویکردهای مختلف، سه مدل دسته بندی بر روی داده های برداری شده آموزش داده شدند:

بیز ساده چند جمله ای

جنگل تصادفی

رگرسیون لجستیک

نتایج مدل‌های کلاسیک

مقایسه عملکرد مدل‌های مختلف نشان داد که Logistic Regression با TF-IDF بهترین نتایج را ارائه داد:

مدل (Model)	روش برداری‌سازی (Vectorization)	دقت (Accuracy)	F1 (Weighted F1) وزن‌دار
Logistic Regression	BoW	۰.۸۲۵	۰.۸۲۳
RandomForest	BoW	۰.۴۹۵	۰.۴۱۰
RandomForest+	BoW	۰.۶۹۸	۰.۷۱۶
NaiveBayes	BoW	۰.۷۴۹	۰.۷۵۵
Logistic Regression	TF-IDF	۰.۸۲۹	۰.۸۲۶
RandomForest	TF-IDF	۰.۴۹۴	۰.۴۱۳
RandomForest+	TF-IDF	۰.۶۹۸	۰.۷۱۶
NaiveBayes	TF-IDF	۰.۷۲۹	۰.۷۱۵

نتایج Word2Vec: Accuracy $\approx$ ۰.۷۷۸, F1 $\approx$ ۰.۷۷۴

بهترین مدل کلاسیک: Logistic Regression + TF-IDF با دقت ۸۲.۹٪ و F1 وزن‌دار ۸۲.۶٪

معماری شبکه LSTM برای cat3_slug

برای بهره‌گیری از اطلاعات ترتیبی و معنایی دقیق‌تر در متن، یک مدل یادگیری عمیق مبتنی بر LSTM طراحی شد:



جزئیات پیکربندی:

- تابع زیان: `sparse_categorical_crossentropy`
- بهینه‌ساز: Adam
- اپوک‌ها: ۱۰
- اندازه بَچ: ۳۲



نتایج و تحلیل آموزش LSTM

مدل LSTM توانست به دقت قابل توجه ۸۴٪ روی مجموعه آزمون دست یابد. تحلیل روند آموزش نشانه‌هایی از بیش‌برازش را نشان داد:

عملکرد مدل


- Accuracy ۰.۸۹ (epoch ۱۰) آموزشی
- Validation Accuracy: ۰.۸۴
- Loss ۰.۲۸ آموزشی
- Validation Loss: ۰.۵۴

مشاهدات کلیدی

- بهترین عملکرد: epoch ۳-۵
- نشانه بیش‌برازش پس از epoch ۵
- تغییرات val_loss روند صعودی از ۰.۴۴ به ۰.۵۴
- توصیه: توقف زودهنگام در epoch ۳-۵

دقت نهایی ۸۴٪ برای دسته‌بندی ۱۶ کلاسه بسیار رضایت‌بخش است (دقت تصادفی: ۶.۲۵٪)

مقایسه روش‌های برداری سازی



مقایسه روش‌های مختلف نشان داد که LSTM بهترین عملکرد را دارد، اما TF-IDF با Logistic Regression نیز با دقت ۸۲٪ گزینه مناسبی با هزینه محاسباتی کمتر است.

پیش‌بینی نوع کاربری (user_type)

با توجه به حجم بالای داده‌های گمشده در ستون user_type (تنها ۲۸۸,۸۷۷ از ۹۹۹,۹۴۵ رکورد)، یک مدل LSTM برای پیش‌بینی این مقادیر طراحی شد.

چالش: عدم توازن کلاس

- عدم توازن شدید کلاس‌ها
- مشاور املاک: ۱۰۲,۰۴۳ نمونه
- شخصی: ۱۳,۳۴۸ نمونه
- نسبت: ۷.۶ به ۱

راه حل: وزن‌دهی کلاس

- وزن‌دهی کلاس (class weighting)
- وزن کلاس اقلیت (شخصی): ۴.۳۲
- وزن کلاس اکثریت (مشاور): ۰.۵۷
- معماری LSTM با sigmoid

نتایج: عملکرد مدل

- Accuracy: ۸۹%
- Weighted F1: ۰.۹۰
- %کلاس شخصی: Recall ۸۱
- %مشاور املاک: Precision ۹۷

بیش از ۷۰۰,۰۰۰ مقدار گمشده با موفقیت پیش‌بینی شد



دستاوردهای کلیدی پروژه

پروژه حاضر با هدف تحلیل جامع آگهی‌های ملکی تهران از پلتفرم دیوار، و با تمرکز بر استخراج الگوهای پنهان در بازار مسکن و ساخت مدل‌های قابل اعتماد برای پیش‌بینی قیمت و دسته‌بندی داده‌ها، طراحی و اجرا گردید.



خوشه‌بندی املاک

شناسایی ۸ خوشه پایدار (۹۶-۱۰۰٪) با پوشش ۹۰.۲۲٪ واریانس



پاکسازی و مهندسی داده

ایجاد مجموعه داده منسجم با مدیریت تکرارها، مقادیر پرت و گم‌شده



تحلیل متنی NLP

دقت ۸۲.۹٪ در دسته‌بندی نوع ملک و ۸۹٪ در شناسایی نوع آگهی‌دهنده



مدل‌سازی قیمت

پیش‌بینی دقیق قیمت و دسته‌بندی سه‌سطحی ارزش املاک



پایان
ممنون از توجه شما